CẬP NHẬT SOURCE HẬU CUỘC THI | 26/10/2026

Proposal bên dưới giữ số liệu lúc nộp ngày 14/10. Profile synthetic local hiện đọc ảnh đã duyệt trong folder Drive Restricted bằng quyền Viewer, lưu mỗi file được nhận vào SQL và tự hiển thị trạng thái chờ, xử lý, kết quả bằng fetch polling khi tab đang mở. File cũ không đổi được bỏ qua; bản sao mới có thể được đánh dấu trùng nội dung. Release unit suite đạt 378/378. Strict ZDR và từ chối thu thập dữ liệu là yêu cầu routing API, không chứng minh hợp đồng không lưu dữ liệu hay che PII. Drive vẫn tắt trên SmartASP; đây chưa phải xác nhận production ready. Xem docs/CURRENT_PROJECT_STATUS.md để biết phạm vi và evidence hiện tại.

Đề xuất giải pháp AURA cho bài toán hoàn ứng

Track: OrganizationAI | **Đề bài:** Spec A The Escalation Referee

Đội: The Deciders | **Tác giả:** Phạm Gia Phú | **Bản chốt:** 14/10/2026

Tóm tắt điều hành

AURA là trợ lý thẩm định tuyến đầu cho quy trình hoàn ứng. Hệ thống nhận ảnh hóa đơn cùng số tiền nhân viên khai, dùng mô hình thị giác để trích xuất dữ kiện có cấu trúc, kiểm tra chéo dữ kiện và áp dụng policy C# tất định. Hồ sơ rõ ràng có thể đi tiếp tự động; hồ sơ thiếu bằng chứng, ngoài chính sách, vượt thẩm quyền hoặc gặp lỗi hạ tầng được chuyển cho con người cùng một câu hỏi cụ thể và nhật ký kiểm toán.

Quyết định thiết kế cốt lõi là tách quyền đọc khỏi quyền duyệt. Qwen3.8 Flash qua OpenRouter/Alibaba chỉ đọc dữ kiện. `PolicyDecisionEngine` mới có quyền tạo `AUTO_APPROVE` hoặc một trạng thái `ESCALATE_*`. Con người xác nhận chuyển tiếp, trả lời câu hỏi ngoại lệ, có thể hoàn tác quyết định gần nhất và vẫn giữ toàn bộ lịch sử.

Candidate hiện phù hợp cho demo có giám sát. Build Release sạch, 163/163 test offline đạt, Verify Harness live đạt 5/5 trong 65,004 giây. Prospective mini-holdout 10 hóa đơn thật mới đạt 8/10 quyết định đúng, 0 missed-escalation, 2 over-escalation fail-safe và 0 lỗi hệ thống/provider/429. Đây là mẫu nhỏ có redaction confounder, không phải production accuracy. Ba phiên người dùng thực tế vẫn là cổng chưa hoàn tất.

1 Bài toán và mục tiêu

Quy trình hoàn ứng có hai rủi ro đối nghịch. Nếu tự động hóa quá tự tin, một hóa đơn mờ, thiếu căn cứ hoặc chứa hạng mục bị cấm có thể được duyệt nhầm. Nếu hệ thống chuyển mọi hồ sơ cho quản lý, tổ chức không giảm được công việc thủ công. AURA tối ưu ranh giới giữa hai lỗi này, ưu tiên không bỏ sót ca cần chuyển tiếp nhưng vẫn đo và công khai chi phí over-escalation.

Mục tiêu Sprint 2 của AURA gồm bốn phần:

- xử lý trọn luồng từ upload đến quyết định và audit;
- tách ba nhóm bất định FACT, POLICY và AUTHORITY;
- tạo câu hỏi để người duyệt có thể quyết định ngay;
- đo missed-escalation, over-escalation, field accuracy, latency và khả năng phục hồi thay vì chỉ trình diễn một output đẹp.

2 Phạm vi nghiệp vụ

AURA nhận một ảnh JPG hoặc PNG tối đa 5 MB và số tiền hoàn ứng do nhân viên khai. Candidate chưa hỗ trợ PDF, nhiều trang, hóa đơn điện tử có chữ ký số, xác minh cơ quan thuế, chống malware, authentication/RBAC production hoặc object storage.

Trạng thái	Điều kiện chính	Người có trách nhiệm tiếp theo
AUTO_APPROVE	Dữ kiện đủ, số tiền khớp, không có hạng mục cấm, không vượt thẩm quyền	Quy trình demo đi tiếp tự động
ESCALATE_FACT	Ảnh/dữ kiện thiếu, mâu thuẫn, ngày cuối tuần/quá hạn hoặc evidence không đủ	Người kiểm tra hóa đơn gốc

Trạng thái	Điều kiện chính	Người có trách nhiệm tiếp theo
ESCALATE_POLICY	Có hạng mục bị cấm hoặc cần ngoại lệ policy	Quản lý quyết định ngoại lệ
ESCALATE_AUTHORITY	Tổng hợp lệ nhưng vượt 1.000.000 VND	Người có thẩm quyền cao hơn
ESCALATE_SYSTEM_ERROR	Provider, contract hoặc hạ tầng không cho kết quả tin cậy	Operator xử lý sự cố, không tạo quyết định giả

Policy áp dụng thứ tự `FACT -> POLICY -> AUTHORITY`. FACT đứng trước vì không được tự động ra quyết định trên dữ kiện chưa đáng tin. Claimed amount không đi vào prompt trích xuất để tránh model bị neo theo số người dùng khai; backend chỉ so sánh sau khi extraction hoàn tất.

3 Luồng xử lý và vai trò con người

```
Ảnh + claimed amount
  -> kiểm file và lưu hồ sơ PENDING
  -> trả HTTP 202
  -> SQL worker claim bằng lease
  -> Qwen trích xuất JSON có evidence
  -> semantic validation và tối đa một repair
  -> policy C# quyết định
  -> AUTO_APPROVE hoặc ESCALATE_*
  -> nhân viên xác nhận chuyển tiếp
  -> quản lý Đồng ý hoặc Từ chối
  -> Audit và Undo
```

Con người xuất hiện tại hai điểm rõ ràng. Nhân viên quyết định có chuyển hồ sơ ngoại lệ vào hàng đợi quản lý hay không; AURA không chuyển âm thầm. Quản lý trả lời câu hỏi có dữ kiện và lựa chọn cụ thể. Undo không xóa quyết định cũ mà thêm một sự kiện mới, giữ trách nhiệm giải trình.

4 Kiến trúc và khả năng phục hồi

Lớp	Thành phần thực tế	Ranh giới
Giao diện	ASP.NET Core Razor, upload bất đồng bộ, polling trạng thái, reviewer và audit	Chưa có identity/RBAC production
Tiếp nhận	Kiểm extension, MIME, magic bytes, kích thước, tên GUID và SHA-256	Chưa có antivirus/CDR
Hàng đợi	SQL là nguồn bền vững; worker dùng lease/reclaim; in-memory channel chỉ đánh thức	Một process demo, chưa có distributed queue
AI extraction	OpenRouter/Qwen3.8 Flash, Alibaba route, reasoning none	Phụ thuộc Internet và upstream quota
Validation	JSON Schema, identifier/money/date/evidence guard, một repair	Không suy số cuối từ subtotal khi evidence rách
Quyết định	Policy C# tất định	Model không có quyền phê duyệt
Con người và audit	Forward, manager YES/NO, Undo, timeline	Audit app-level, chưa phải WORM compliance

AI concurrency được giữ ở 1 để giảm burst upstream. Verify có khóa riêng để hai batch không chạy chồng; bốn client phụ nhận HTTP 409 thay vì nhân số lần gọi AI. Nhiều upload khác nhau vẫn được nhận HTTP 202 và xếp hàng trong SQL. Gate hiện tại là per-process; scale nhiều IIS worker/server cần distributed limiter và circuit state.

5 Phương pháp đánh giá

AURA tách các loại bằng chứng để tránh trộn lẫn mục đích:

Phép đo	Chứng minh	Không chứng minh
163 test offline	Correctness của policy, contract, queue, fallback, audit và UI contract	Độ chính xác trên 163 hóa đơn
Verify 5 ca	Gate nhanh đúng yêu cầu Spec A, 3 AUTO và 2 ESCALATE	Production accuracy
Prospective holdout 10	Khả năng tổng quát tại lượt đầu trên mẫu nhỏ đã khóa	Hiệu năng sản xuất quy mô lớn
Regression 12 ảnh đã biết	Stability, variance và queue/concurrency	Holdout mới hoặc causal A/B
User study	Usability, review time, tải công việc và tác động tiêu cực	Model accuracy

Ground truth, expected status và SHA-256 được khóa trước request đầu tiên. Raw evidence không bị sửa sau khi xem output. Lượt chạy lại trên dữ liệu đã biết luôn được gọi đúng là regression hoặc stability repeat.

6 Kết quả đã kiểm chứng

Gate	Kết quả	Diễn giải an toàn
Release build	0 warning, 0 error	Gate build hiện hành
Automated tests	163/163	Test code offline, không gọi paid AI API
Live Verify	5/5 trong 65,004 giây	Đạt gate 5 ca dưới 90 giây
Prospective mini-holdout	8/10, 0 missed, 2 over, 0 lỗi hệ thống/provider/429	Một official run, không rerun để săn số
Field trọng yếu prospective	28/30	Chỉ date, canonical identifier và final total
Regression 12 source bytes	10/12, 0 missed, 2 over, 35/36 field	Dữ liệu đã biết, không phải holdout
Sequential repeat	11/12, 0 missed, 1 over, P95 32,903 giây	Stability evidence
Năm upload đồng thời	5/5 hoàn tất, E2E P95 93,684 giây	Queue integrity, không phải Verify SLA

FAHASA là over-escalation ổn định vì validator chưa công nhận dòng `Thanh toán 91.500 đ` là final-payable label. GS25_2 biến thiên ở merchant name gần vùng blackout. Team không hard-code merchant và không nới guard ngay trước demo. Bản sửa an toàn cần fixture dương cho final payable và fixture âm cho tender, tiền khách đưa và tiền thối.

7 Câu chuyện phát triển sản phẩm

Điểm ngoặt của AURA không đến từ một lần đạt 15/15 regression. Official real-receipt holdout từng phát hiện một missed escalation: model có thể trả JSON hợp lệ nhưng dữ kiện vẫn sai nghĩa. Sau đó AURA chuyển từ “model đọc được hóa đơn” sang “mọi dữ kiện quan trọng phải có vai trò và provenance”. Evidence contract v2 tách identifier, raw date, printed final total và discount; semantic validator chặn mâu thuẫn; kết quả không chắc chắn luôn dừng cho người.

Từ đó, nhóm không dùng một con số đẹp làm kết luận. Mỗi phép đo có nhãn đúng: blind holdout, post-holdout regression, stability repeat hoặc user study. Đây là câu chuyện chính khi trình bày với doanh nghiệp: AURA trưởng thành qua việc phát hiện giới hạn, khóa evidence và chuyển lỗi thành guard có thể kiểm thử.

8 Nghiên cứu người dùng

Đề Track yêu cầu ít nhất ba người đang trực tiếp xử lý quy trình, nêu danh tính và chức danh thật, phản hồi nguyên văn, một thay đổi sản phẩm từ feedback và một tác động tiêu cực cụ thể. Tại thời điểm phiên bản này, gate đó chưa hoàn tất. AURA đã chuẩn bị protocol và biểu mẫu đồng thuận; proposal không điền giả người dùng hoặc trích dẫn.

Mỗi phiên dự kiến 20-25 phút với dữ liệu tổng hợp: một upload routine, một escalation/handoff, một manager decision/Audit/Undo. Người điều phối ghi task success, review time, số lần cần trợ giúp, quote do người tham gia tự viết hoặc xác nhận, điểm khó hiểu và tác động tiêu cực như thời gian chờ AI, tải review dồn hoặc nguy cơ ỷ lại.

9 Quyền riêng tư và đạo đức

Ảnh hóa đơn thật chỉ được dùng khi chủ dữ liệu cho phép và đã redaction. Raw receipt, raw provider response, database, log vận hành và secret được giữ ngoài repository công khai. Proposal, slide và video chỉ dùng dữ liệu tổng hợp hoặc số liệu tổng hợp không chứa PII.

Evidence localization bằng bounding box hiện là prototype tổng hợp cô lập. Ảnh gốc giữ nguyên bytes, region JSON gắn SHA-256 và browser vẽ overlay. Tính năng chưa có annotation unseen và chưa tham gia quyết định policy, nên không được trình bày như capability production.

10 Giới hạn và lộ trình

Candidate là supervised MVP, chưa phải hệ thống hoàn ứng production. Ba ưu tiên tiếp theo là:

1. hoàn tất ba user session có consent và một thay đổi truy được bằng commit;
2. sau submission freeze, giảm over-escalation bằng fixture dương/âm độc lập mà không tăng missed-escalation;
3. bổ sung authentication/RBAC, private object storage, retention, monitoring, distributed provider limiter và safe PDF pipeline trước pilot thực tế.

Evidence overlay chỉ đi tiếp sau khi có OCR word boxes, annotation độc lập và benchmark region recall/false highlight. Ollama 4B được giữ làm contingency local có giám sát; fallback trên live vẫn tắt vì latency và endpoint loopback không phù hợp hosting công cộng.

11 Khả năng tái lập

- Live: https://bondphupham-001-site1.ltempurl.com/
- Health: https://bondphupham-001-site1.ltempurl.com/healthz
- Repository: https://github.com/BondPhuPhamzZ/AURA
- Runbook: `AURA/docs/RUNBOOK.md`
- Business rules: `AURA/BUSINESS_RULES.md`
- Workflow: `AURA/submission/AURA_WORKFLOW_SPEC.md`
- Current status: `AURA/docs/CURRENT_PROJECT_STATUS.md`
- User-study protocol: `AURA/docs/USER_STUDY_PROTOCOL.md`

Kết luận

AURA chứng minh một cách triển khai AI có trách nhiệm cho hoàn ứng: model xử lý dữ liệu biến thiên, code tất định giữ quyền quyết định, con người xử lý ngoại lệ và evidence được giữ nguyên để tái lập. Bằng chứng hiện tại đủ cho demo có giám sát và một pilot nhỏ có kiểm soát; chưa đủ cho claim accuracy sản xuất hoặc vận hành không giám sát.